

学生成绩的影响因素分析

数据来源：UCI Student Performance Data Set (Cortez & Silva, 2008) , 1,044 条记录

结论 ① 期末成绩几乎由平时成绩决定

结论 ② 缺课次数少时影响较小，大于10次成断崖式下降


结论 ③ 支持组和无支持组的差距，绝大部分来自起点差异，而不是支持本身的效果

数据来源与处理

来源	UCI Machine Learning Repository · Student Performance Data Set (Cortez & Silva, 2008)
规模	1,044 条记录 (数学 395、葡语 649) 。3 张主表按 student_id 关联, 另附 3 张字典表
因变量	g3 (0–20 分, 期末成绩)
解释变量	学习行为: studytime、failures、absences; 家庭背景: medu、fedu、famsize; 外部支持: schoolsup、famsup、paid
清洗口径	剔除 g3 = 0 的记录 54 条 (5.2%) , 剩余 990 条。

变量组	代表字段	取值
学习行为	studytime、failures、absences	档位与次数
家庭背景	medu、fedu、famsize	0–4 级、家庭人数档
外部支持	schoolsup、famsup、paid	yes / no

发现一：平时成绩与期末成绩



方法

计算 g1、g2 与 g3 的相关系数（数学、葡语分别算）。
Excel 公式：=CORREL(g2列, g3列)。


发现

数学的g2与g3的相关性均在0.9以上，葡萄牙语偏弱但也均在0.85以上

所以呢

期末成绩与平时成绩高度相关，还有那些因素会影响期末成绩

发现二：缺课与期末成绩



方法

把 absences 分成 0 次、1-5 次、6-10 次、11 次以上四档，分别计算平均 g3，并先剔除 g3 = 0 的记录。


发现

整体缺课次数与成绩成负相关，但缺课次数在10次以内差别不大，超过10次差距明显上升

所以呢

缺课超过 10 次可以作为学业预警信号，单独跟进

发现三：家庭支持与期末成绩



方法

按 famsup / schoolsup / paid 分组比较平均 g3；再把因变量换成进步幅度 ($g3 - g2$) 比一次，用来排除「起点不同」的干扰。

发现

受到支持的学生反而期末成绩不如未受到支持的学生，与直觉相反

所以呢

这不是支持无效，而是支持被分配给了原本较弱的学生（选择效应）

结论与局限

三条结论

- ① 期末成绩几乎由平时成绩决定
- ② 缺课次数少时影响较小，大于10次成断崖式下降
- ③ 支持组和无支持组的差距，绝大部分来自起点差异，而不是支持本身的效果

局限

相关不等于因果。数据来自观察，不是实验。

样本为 2005–2008 年葡萄牙两所学校的学生，不能直接推广到其他地区。

$g3 = 0$ 的缺考与辍学记录已剔除，可能低估辍学风险。

只看单科期末成绩，没有考虑教师、班级等未记录因素。

数据来源：UCI Machine Learning Repository · Student Performance Data Set (Cortez & Silva, 2008) 。分析工具：Excel。