数据分析作品 • 2026.10

学生成绩的影响因素分析

数据来源：UCI Student Performance Data Set（Cortez & Silva, 2008），1,044 条记录

结论 ① 期末成绩几乎由平时成绩决定

结论 ② 缺课次数少时对期末成绩影响较小，大于10次成断崖式下降

结论 ③ 支持组和无支持组的差距，绝大部分来自起点差异，而不是支持本身的效果

吴瑶珍 · 2026.10 · 用 Excel 完成

数据来源与处理

来源

UCI Machine Learning Repository · Student Performance Data Set（Cortez & Silva, 2008）

规模

1,044 条记录（数学 395、葡语 649）。3 张主表按 student_id 关联，另附 3 张字典表

因变量

g3（0–20 分，期末成绩）

解释变量

学习行为：studytime、failures、absences；家庭背景：medu、fedu、famsize；外部支持：schoolsup、famsup、paid

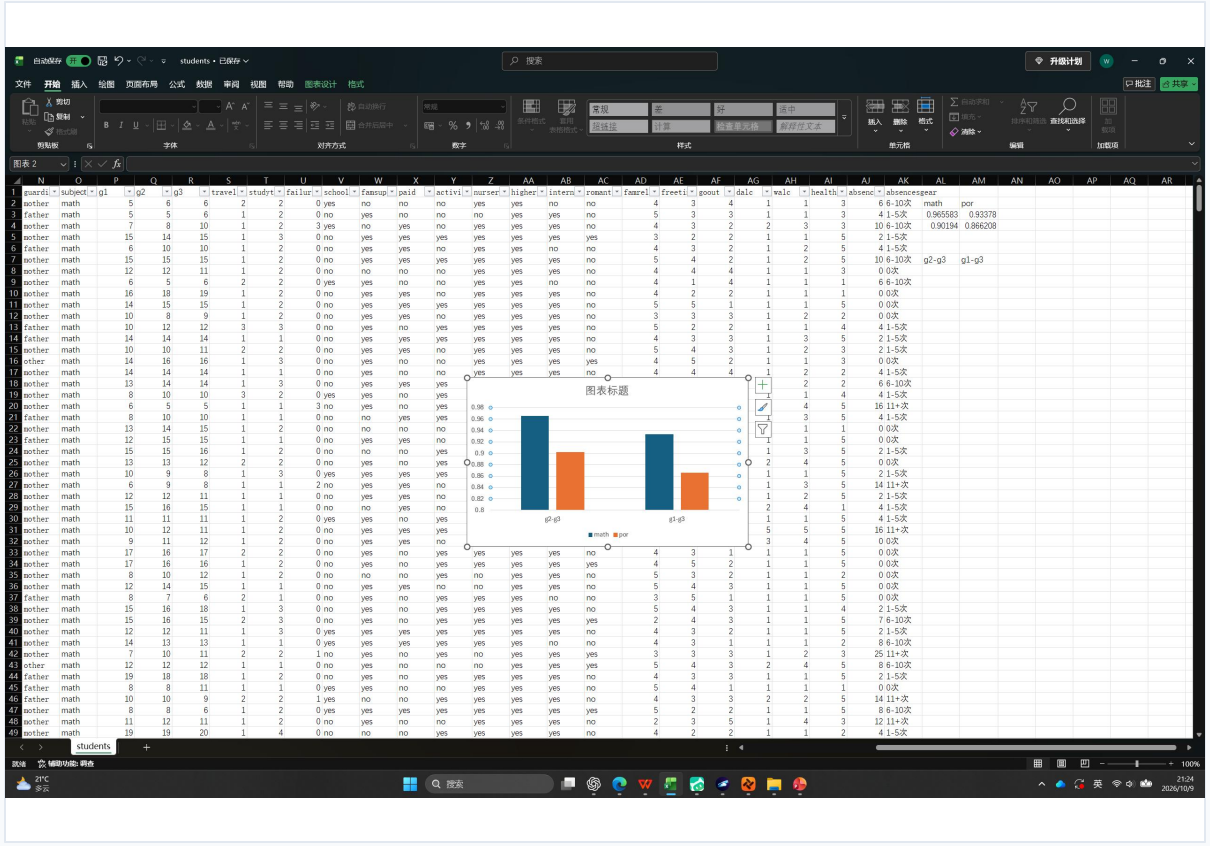
清洗口径

剔除 g3 = 0 的记录 53 条（5.1%），剩余 991 条。

变量组	代表字段	取值
学习行为	studytime、failures、absences	档位与次数
家庭背景	medu、fedu、famsize	0–4 级、家庭人数档
外部支持	schoolsup、famsup、paid	yes / no

家庭支持（famsup）为数据集中“家庭是否提供教育支持”的二元自报变量（是/否），不区分支持的形式与强度；它与学校支持（schoolsup）、付费补习（paid）、父母学历（medu/fedu）为不同变量。

发现一：平时成绩与期末成绩



方法

分别计算 g1、g2 与 g3 的相关系数（数学、葡语分别算）。
Excel 公式：=CORREL

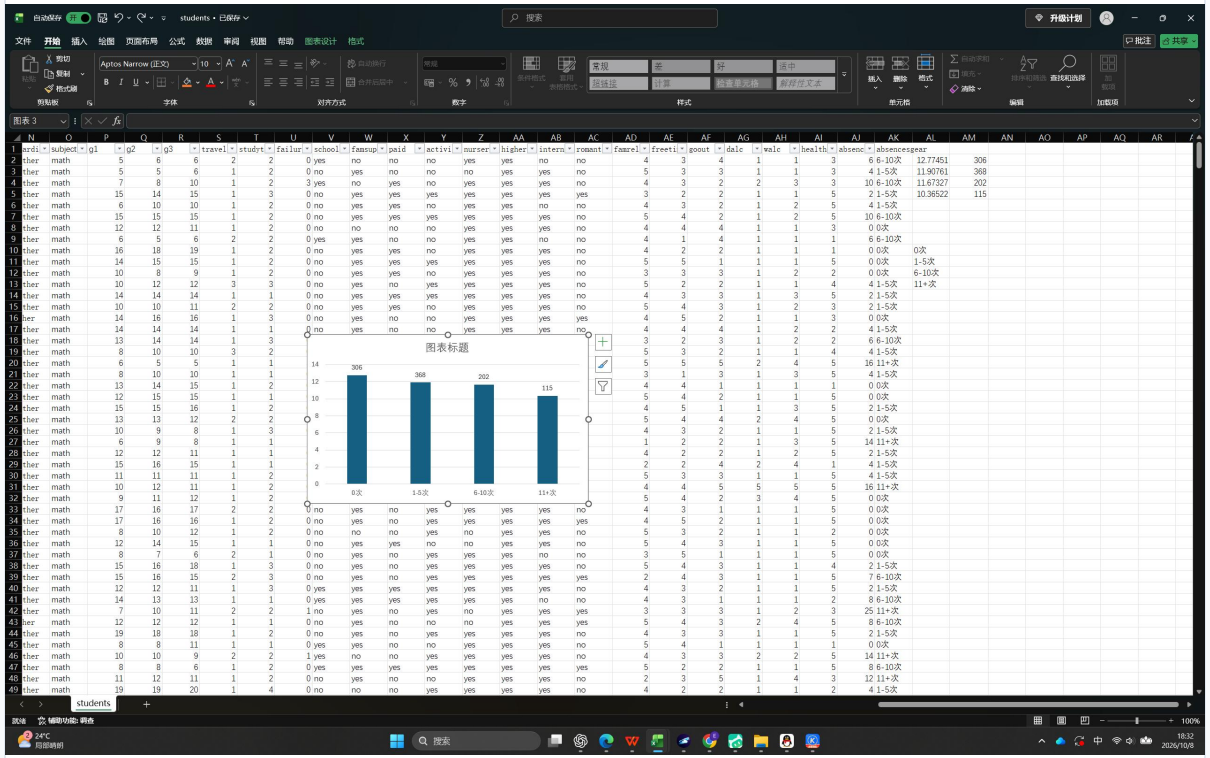
发现

数学的g1、g2与g3的相关性均在0.9以上，葡萄牙语偏弱但也均在0.85以上。

所以呢

期末成绩与平时成绩高度相关。

发现二：缺课与期末成绩



方法

把 absences 分成 0 次、1–5 次、6–10 次、11 次以上四档，分别计算平均 g3。
Excel 公式：=AVERAGEIFS

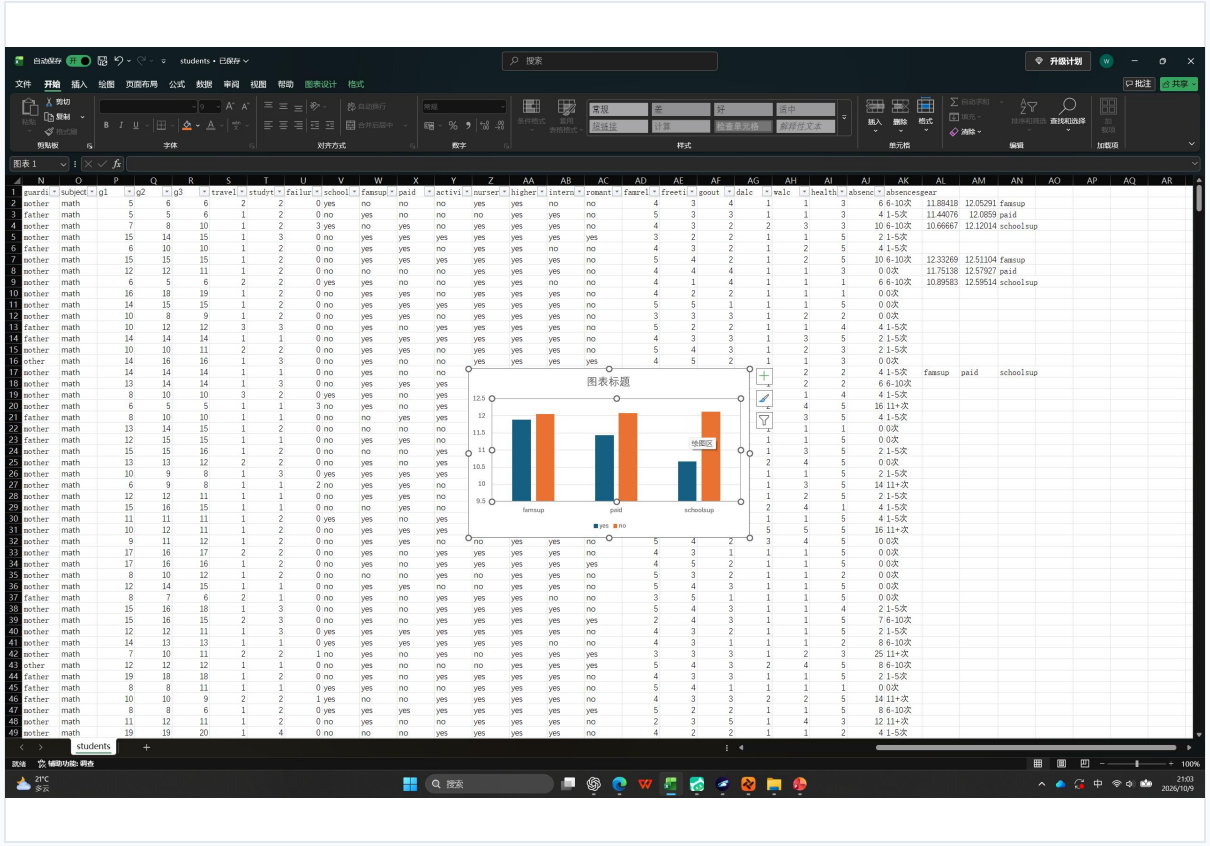
发现

整体上缺课次数与成绩成负相关，但缺课次数在10次以内期末成绩差别不大，超过10次差距明显上升。

所以呢

缺课次数 10 次可以作为学业预警信号，单独跟进。

发现三：家庭支持与期末成绩



方法

按 famsup / schoolsup / paid 分组比较平均 g3；再把因变量变为平时成绩重新计算。
Excel 公式：=AVERAGEIFS

发现

受到支持的学生反而期末成绩不如未受到支持的学生，与直觉相反，但是受到支持的学生的平时成绩低于未受到支持的同学。

所以呢

这不是支持无效，而是支持被分配给了原本较弱的学生（选择效应）。

结论与局限

三条结论

① 期末成绩几乎由平时成绩决定

② 缺课次数少时对期末成绩影响较小，大于10次成断崖式下降

③ 支持组和无支持组的差距，绝大部分来自起点差异，而不是支持本身的效果

局限

相关不等于因果。数据来自观察，不是实验。

样本为 2005–2008 年葡萄牙两所学校的学生，不能直接推广到其他地区。

g3 = 0 的缺考与辍学记录已剔除，可能低估辍学风险。

只看单科期末成绩，没有考虑教师、班级等未记录因素。

数据来源：UCI Machine Learning Repository · Student Performance Data Set（Cortez & Silva, 2008）。分析工具：Excel。